

회귀분석팀

6팀

심은주
진수정
문병철
이수정
임주은

INDEX

1. 다중공선성

2. 변수선택법

3. 축소 추정

- 다중공선성이란?

예측변수 X들 간의 선형관계가 존재하는 경우

$$y_i = \beta_0 + \beta_1 x_{1i} + \cdots + \beta_p x_{pi} + \varepsilon_i$$

나머지 X 변수들이 고정되었을 때,
 x_1 이 1단위 증가하면 y 는 평균적으로 β_1 만큼 증가함을 의미


개별 변수 해석 시, '다른 변수를 고정한 상태에서 해당 X의 증분'

Uncorrelated한 경우만 가능

정확한 회귀분석을 위해선 다중공선성이 크면 안된다!

- 다중공선성의 판별법

상관계수 플랏



- 절댓값 기준
상관계수가 0.7이상일 경우
다중공선성 의심
- R의 'Corrplot' 패키지 이용

- 다중공선성의 판별법

VIF(Variance Inflation Factor, 분산팽창인자)

$$VIF = \frac{1}{1-R_j^2}, \quad j = 1, \dots, p$$

R_j^2 : x_j 를 $x_1 + \dots + x_p$ 으로 회귀식을 적합했을 때, 도출되는 R^2 값

- VIF가 1이면, 다중공선성 없음 ($R_j^2=0$ 이므로)
- VIF가 10이상이면, 심각한 다중공선성 존재

- 변수선택법이란?

후보 변수들 중에서 불필요한 변수들을 제거하여
적절한 변수들의 집합을 찾는 방법



다중공선성이
존재할 때 많이 사용!

그래서 뭐가 좋은데..?



- 높은 상관관계를 가지는 변수들 중 일부만을 선택 가능
- 높은 상관관계를 가지는 변수들의 존재를 정당화

변수선택법을 통해 최종 모델에 대한 확신을 얻을 수 있음!

- 변수선택의 척도

수정결정계수(R_a^2)

벌써 까먹은 건 아니쥬?



$$R_a^2 = \frac{SSR/p}{SST/(n-1)} = 1 - \frac{SSE/(n-p-1)}{SST/(n-1)}$$

회귀식의 설명력을 의미



수정결정계수가 더 큰 모델을 사용하자!

- 변수선택의 척도

Mallows(C_p)

$$C_p = \frac{SSE_p}{\hat{\sigma}^2} + (2p - n)$$

p : RM에서 사용한 독립변수 개수

$\hat{\sigma}^2$: FM의 오차항의 분산의 추정값

n : 관측치의 개수

- 변수를 추가하면 SSE는 무조건 작아지기 때문에, $2p$ 를 패널티로 넣음
- $C_p \approx p$ 일수록 bias가 작음, 좋은 모델
- C_p 값을 이용하여 모델을 비교할 때에는
동일한 독립변수의 전체 집합을 가진 모델일 경우에만 사용 가능

- 변수선택의 종류

변수선택법은 **경험적**인 방법



명확한 답이 존재하는 것이 아니라,

직접 알고리즘에 따라 해당하는 **모든 경우를 계산**해서 가장 좋은 회귀식을 찾는다!

Best Subset
Selection


전진선택법

후진제거법

단계적 선택법

- 축소 추정이란?

각각 개별 베타 추정량을 **0으로 수축**시키는 방법



둘 다 가질 순 없지...

불편성을 포기하되,
전체 $MSE(Bias^2 + Variance)$ 를 더 작게 하는
추정량 얻을 수 있다!



- Ridge Regression (L2 Regularization)

$$\hat{\beta}^{ridge} = \underset{\beta}{\operatorname{argmin}} \sum_i (y_i - x_i^T \beta)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

- 위의 식을 **최소화**하는 β 값을 가짐
- 앞 부분: **SSE**, 회귀식이 데이터에 잘 적합하여 SSE를 작게 만드는 계수 추정치를 찾음
- 뒷 부분: **shrinkage penalty**로 β 값들이 0에 가까울 수록 작아짐
→ 이 항이 계수 추정치들을 **0으로 축소하는 영향**을 가짐

- Ridge Regression (L2 Regularization)

$$\hat{\beta}^{ridge} = \underset{\beta}{\operatorname{argmin}} \sum_i (y_i - x_i^T \beta)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

조절 모수 λ : SSE항과 패널티항을 조절하는 역할

좋은 λ 값 선택 중요
주로 CV를 통해 튜닝

- $\lambda=0$ 이면, 패널티 효과가 없어 최소제곱추정치 생성
- $\lambda \rightarrow \infty$ 이면, 패널티 효과가 커져 계수 추정치가 0에 가까워짐

\therefore Ridge regression은 각각의 λ 값에 따라서 다른 추정치 집합들을 만듦

- Lasso Regression (L1 Regularization)

$$\hat{\beta}^{lasso} = \underset{\beta}{\operatorname{argmin}} \sum_i (y_i - x_i^T \beta)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

Ridge와 비슷하게 **패널티**를 주어 계수 추정치들을 0으로 **축소**하는 방법

- Penalty term이 **절댓값**으로 들어감
- Ridge와 달리 **변수 선택**의 효과가 있음

변수 잘 가고~~



- Elastic Net

Lasso와 Ridge를 **절충**하여 각각의 단점을 **보완**한 정규화 방법

$$L_{enet}(\hat{\beta}) = \frac{\sum_i (y_i - x_i^T \beta)^2}{2n} + \lambda \left(\underbrace{\left(\frac{1-\alpha}{2} \right) \sum_j \beta_j^2}_{\text{Ridge part}} + \underbrace{\alpha \sum_j |\beta_j|}_{\text{Lasso part}} \right)$$

α 는 Ridge와 Lasso의 **가중치**로,

$\alpha = 0$ 이면 식은 **Ridge**가 되고, $\alpha = 1$ 이면 **Lasso**가 됨

- Adaptive Lasso Regression

$$\widehat{\beta}^{*(n)} = \underset{\beta}{\operatorname{argmin}} \left\| y - \sum_j x_j \beta_j \right\|^2 + \lambda_n \sum_j \widehat{w}_j |\beta_j|$$

where $\widehat{w}_j = \frac{1}{|\widehat{\beta}|^\gamma}$ $\widehat{\beta}$: initial estimate (ex. OLS)

- 계수 추정량이 클수록 작은 가중치를 줌으로써, Sparsity는 유지하되 Bias를 줄일 수 있음
- λ 를 적절히 선택한다면, Oracle Properties를 만족하게 됨